

공개 데이터 기반 창업 입지 평가 모델

매출 잠재력 × 생존 가능성 통합 평가

데이터마이닝 학기말 프로젝트

서울시 우리마을가게 상권분석 6종 API · 소상공인진흥공단 창업기상도 API

※ 타깃 누설 자기검증 · 누설 제거 정직 성능 · 한계 명시 · 외부 API 교차검증

1. 문제 정의 (10%)

- 자영업 폐업·입지 선택 문제 / 목표·산출물·정직성 원칙

2. 데이터 수집 및 이해 (20%)

- 서울시 상권 6종 API + 팀 데이터 + 창업기상도 API / EDA·결측·폐업 노이즈

3. 변수 선택 및 변수 생성 (30%, 최다 비중)

- 파생변수 군·미사용 원자료 피처화·창업기상 파생·누설 발견·제거·생존측·정의 민감도

4. 모델 구현 및 성능 비교 (15%)

- 7종×4변환×2라벨=56실험·누설 검증·90% 경로·단일 vs 융합

5. 결과 분석 및 해석 (15%)

- 변수 중요도·창업기상도 비교(과거 vs 미래)·4사분면·정직한 한계

6. 시행착오 (정직한 연구 과정)

- 누설 94→84·생존 모델 반복 누설·distillation 폐기·90% 집착

7. 결론 및 후속 과제

배경

- 자영업 폐업률 높음 — 창업 입지 선택이 성패의 핵심 변수
- 기존 접근: (1) 매출 중심 상권분석, (2) 정부 합성지수(창업기상도) 의존 — 둘을 결합·검증한 사례 부족

문제 정의

- “어느 자치구·읍종에 창업하면 (가) 매출이 높고 (나) 오래 살아남는가?”
- 공개 데이터만으로 (자치구·읍종) 단위 입지를 정량 평가하고, 공공 API와 교차검증

기존 방식의 한계

- 매출만 보면 경쟁 포화 지역(고매출·저생존) 함정을 놓침 → 매출 × 생존 동시 평가 필요

목표 (3축)

- (1) 매출 잠재력 예측 모델 (2) 생존 가능성 지표 (3) 둘을 결합한 통합 입지점수

분석 단위

- 자치구 25 × 업종 50 × 분기 24 (2020 Q1 ~ 2025 Q4)

최종 산출물

- (자치구·업종) 성공확률 + 매출 × 생존 4사분면 등급(①최적 / ②고위험·고수익 / ③안정·저성장 / ④회피)

정직성 원칙 (프로젝트 전반에 적용)

- 타깃 누설 검증 · GroupKFold(정체성 누수 차단) · 외부 API 교차검증(상관+값일치도) · 측정 불가 항목은 한계로 명시

서울시 우리마을가게 상권분석 서비스 — 분기별 24개 분기

Selng(매출) : 상권·업종별 매출 금액/건수

Stor(점포) : 점포수·개업률·폐업률·개·폐업 점포수·프랜차이즈수

Fipop(유동인구) : 성별·연령(10~60)·시간대(6)·요일(7)

WrcPopltn(직장인구): 성별 × 연령 21종

Fclty(집객시설) : 지하철·버스·대학·병원·은행·약국·학교·극장 등 20종

lx(변화지표) : 상권 다이내믹/확장/정체/축소 등

- 상권→자치구 매핑: TbgisTrdarRelm.csv (상권코드→자치구)

팀 수집 데이터

- team1 임대료·공실률(부동산), team2 가맹점·창업비·매출(공정위), team3 행정동 미시입지, team4 인구·물가·폐업·강수

소상공인진흥공단 창업기상도 OpenAPI (외부 검증용, 신규 수집)

- 인증: certKey 쿠키 방식, 사용기간 2026-05-28~09-30
- 엔드포인트: /cstmz/api/indicator/overall/area (자치구·업종·월)
- 지표 5종: 종합 / 경쟁력 / 생존력 / 전망 / 관심도 (각 점수·등급·백분위)
- 수집: 19개 업종(우리 업종과 1:1 매핑) × 2025 Q3·Q4, 캐시 저장(재호출 없이 재현)
- (확장 50업종 시도 → API 503 한도로 19종 유지)

업종 선정

- 매출 raw 약 63개 업종 → 매출 누적 99% 커버하는 상위 50개 선정

통합 테이블 (features.csv)

- (자치구·업종·분기) 17,568행 × 164컬럼 (6종 API + 팀 + 파생 통합)

분포 특성

- 매출: 우편향(평균 > 중앙값) → 소수 대형 점포가 평균을 끌어올림
- 점포당 매출 = 상권 합계 ÷ 점포수 (평균이며 개별 점포 아님)
- 폐업: 희소 사건 — 상권·업종·분기 단위 87%가 0

발견한 데이터 품질 문제 (감사로 색출)

임대료·공실 : 2020~2022 전 분기 결측 (약 51%)

1인가구 : 원본이 2010년만 → 조인 후 100% 결측, 사용 불가

margin_proxy : 독립 마진 데이터 아님 = 매출 $\times$ 0.01 재척도화 (corr 0.998)

결정적 단위 한계

- 매출은 상권(집계) 합계, per-store는 평균 → 개별 점포 매출·점포 간 분산 데이터 없음
 - → 본 모델은 "상권 단위 매출 수준 스크리닝"이며, 개별 점포 수익·리스크 예측이 아님
 - → BEP·손익분기 초과확률은 점포 분산이 아닌 모델 오차 기반 = 참고용 (한계 명시)

폐업률은 단위에 따라 신호/노이즈가 갈림 (실측)

상관·업종·분기 : 87%가 0, split-half 신뢰도 0.28 → 노이즈

자치구·연 : 인접연도 상관 $r=0.97$ → 안정

함의

- 폐업을 ML로 직접 예측 = 노이즈 예측(정확도 67% 천장) → 생존은 "측정 지수"로 다뤄야 함

진짜 생존율은?

- 코호트(개별 사업체 개·폐업일)가 필요 → 행안부 지방행정인허가(LOCALDATA) 재수집 필요
 - data.go.kr 접근 가능하나 키·대규모 정제 필요 → 본 프로젝트 범위 밖(후속 과제)

변수 4그룹

A 카테고리 : 자치구·업종·분기 원핫 (약 80)

B raw : 점포수·유동인구·직장인구·시설·영업개월 등

C 가공·파생 : 시간패턴·연령분포·모멘텀·집객 등

D 외부 : 임대료·공실·인구밀도·거시

변수 선택 절차

- 분산 0 제거 · $|상관| \geq 0.9$ 중복 제거 · 타깃 누설 제거(핵심, 3-5)

핵심 메시지 (30% 비중)

- 변수 생성·선택이 본 프로젝트의 중심 — (1) 미사용 원자료 대량 피처화 (2) 누설 발견·제거 (3) 생존축 설계 (4) 정의 민감도

momentum : 매출 분기 차분 (추세)

avg_ticket : 매출 / 거래건수 (객단가)

peer_avg_sales : 동일 업종 타 지역 평균 매출

lunch_bias : 점심 시간대 매출 편중도

weekend_bias : 주말 매출 편중도

age_entropy : 연령대별 매출 분포의 엔트로피(다양성)

anchor_score : 집객시설 기반 앵커 점수

season_amplitude: 계절 매출 진폭

rent_to_sales : 임대료지수 / 매출 (※ 후에 누설로 판정·제거)

- 주의: momentum·avg_ticket·peer_avg_sales·rent_to_sales·margin_proxy는 매출 파생 → 누설(3-5)

초기 features는 "총량"만 사용 → 상세 분포 미활용 발견

추가 생성 (자치구·분기 단위)

유동인구 : 여성비, 연령 10~60 비율, 시간대(아침/점심/저녁/밤) 비율, 요일·주말 비율

직장인구 : 여성비, 연령대 비율, log 총량

시설 : 은행·약국·유치원·초중고·극장·대형마트·터미널 등 20종 (log1p)

결과 (정직)

- features.csv 127 → 164컬럼. 성공 식별 AUC 0.934 → 0.936 (+0.002)
 - → 더 넣어도 미미 — 천장은 "변수 부족"이 아니라 "라벨 경계 노이즈"(실측 확인)

임의 가중치 배제, 데이터가 말하는 구조만 사용

- overall = 4개 하위지표 단순합 (corr 1.0) 확인 → overall 제외
- 상관 군집: 경쟁력↔관심도 $r=0.47$ / 생존력↔전망 $r=0.39$, 군집 간 $\approx 0 \rightarrow$ 2개 직교 축

생성 (37종)

- z-score(업종·분기 내) · 백분위 · 합성축 (market_power, sustainability) · gap(± 1) · 2원 평균제거 잔차 · PCA

정직 검증

- 각 파생변수를 실제 폐업/매출과 대조 → 근거 없는 사업적 해석(거품/포화 등)은 제거
 - 예: "PCA가 가중치를 0.5/0.5로 정함" 주장 → 2변수 PCA는 항상 0.5/0.5라 순환논증, 철회

문제 발견

- 초기 "분류 정확도 94% / 회귀 R^2 0.92"가 비정상적으로 높음 → 변수 전수 점검

누설 변수 5종 (매출에서 파생되어 매출을 예측 = 순환)

rent_to_sales : 임대료 / log(매출) → log매출과 corr -0.98

momentum : 매출 차분

avg_ticket : 매출 / 건수

peer_avg_sales : 업종 매출 평균

margin_proxy : 매출 $\times$ 0.01

조치

- 5종 제거 후 전 노트북(nb04~24) 재학습 → 진짜 성능 = 이진 84% / R^2 0.64로 정정

시도1: 폐업률 ML 예측 → 실패

- GroupKFold 정확도 67% (기준선 53%), 회귀 $R^2 \approx 0$
- (주의) 무작위분할+안정타깃이면 98~100% → (자치구·업종) 정체성 암기 누설, GroupKFold로 적발

채택: 평균 영업기간 (OPR_SALE_MT_AVRG)

- 측정 지수(예측 아님), split-half 신뢰도 $r=0.94$ — 매우 안정
- 창업기상 생존지표와 $r=0.47$ (외부 타당도 확보)

의미

- 생존은 "정확도"가 아니라 "신뢰도·타당도"로 평가하는 측정 지수가 정석 (소상공인 상권분석 표준 = 영업기간)

(1) 시간 누수

- 미래 정보로 과거 예측 방지 → 2024년+ 홀드아웃 / TimeSeriesSplit 5겹

(2) 정체성 누수 (입지 평가 특유)

- 같은 (자치구·업종)이 학습·검증에 동시 등장 → 정체성 암기
- → 핵심 검증은 GroupKFold(그룹=자치구·업종): “안 본 조합 일반화” 측정

적발 사례

- 단일 “성공” 타겟 무작위분할 학습 시 100% → 정체성 누설. GroupKFold로 정상화

교훈

- 자치구·업종 정체성이 타겟과 거의 1:1이면 무작위 분할은 거짓 성능을 만든다

"성공"은 값 선택 → 7가지 정의를 동일 조건으로 비교 (GroupKFold)

정의	비율	예측AUC	API종합 κ
고매출	0.62	0.714	+0.12
장기영업	0.62	0.934	+0.06
저폐업(생존)	0.51	0.563	+0.07 ← 예측 불가(노이즈)
고매출&장기영업	0.38	0.786	+0.10
고매출&저폐업	0.30	0.565	+0.13

결론

- 저폐업 정의는 어떤 조합이든 예측 불가 / 매출 기반이 예측 가능 + API와 가장 정합
- → 채택: 성공 = 고매출 & 장기영업 (정의 명시·공시)

타겟: log 매출, GroupKFold/ 홀드아웃

모델	R^2	RMSE
GradientBoosting	0.596	1.327 ← 최고
HistGradientBoosting	0.588	1.340
RandomForest	0.553	1.395
ExtraTrees	0.534	1.425
LinearRegression	0.529	1.432
KNN(k=7)	0.492	1.488
DecisionTree	0.419	1.591
기준선(평균예측)	-0.004	2.091

- 부스팅 우위. 누설 제거 전 R^2 0.92는 허수였음을 명확히 보여줌

타겟: 매출 상위 33% 여부, 기준선(다수) 66.0%

모델 정확도 F1(macro)

HistGradientBoosting 0.836 0.811 ← 최고

GradientBoosting 0.835 0.809

KNN(k=7) 0.831 0.809

RandomForest 0.825 0.790

ExtraTrees 0.811 0.767

Logistic 0.804 0.773

DecisionTree 0.804 0.774

- 기준선 66% 대비 +17.6%p / 3분류는 HistGB 68.9%(기준선 34%)

변환 4종 × 모델 7종 × 라벨 2종 = 56실험

- $\log_1 p \approx \text{basic}$ (동등), $\text{poly2} \cdot \text{pca95}$ 는 오히려 저하 → 추가 변환 이득 없음

GridSearchCV 튜닝

- HistGB: $\text{learning_rate} \cdot \text{max_iter} \cdot \text{max_depth}$ 탐색 → 소폭(+0.5%p)

TimeSeriesSplit 5겹

- 시간 분할에서도 정직 성능 재현 → 시간 누수 없음 확인

비지도 (보조)

- KMeans·PCA — 군집은 자치구 정체성을 주로 재현(해석 주의), PCA 2D는 분산 11.6%만 설명

Operational(누설 포함) vs Strict(누설 제거)

지표	Operational	Strict
이진 정확도	0.943	0.836 (-10.6%p)
회귀 R^2 (점포당)	0.873	0.638 (-0.23)

정직한 결론

- 초기 94%/0.92는 타깃 누설 산물 → 폐기. 진짜 성능 = 84% / R^2 0.64

Ablation 부수 발견

- 외부변수(임대료·인구밀도)의 정확도 기여는 누설 제거 후 -1%p (사실상 0)
 - 기존 “외부변수 +4.75%p 기여” 주장은 누설(rent_to_sales 등)이 만든 허수

3분위 high-vs-rest는 ~84%가 천장 (라벨 경계 노이즈)

- “중간(mid)” 등급이 본질적으로 모호 → 추가 변수·행정동 미세화·양상블로도 안 오름(실측)

명확등급 (high vs low, 애매한 mid 보류)

구성	정확도
----	-----

high-vs-rest (3분위 전체)	0.836
-----------------------	-------

+ 유동인구 상세 피쳐	0.843
--------------	-------

high-vs-low (mid 33% 보류)	0.896
--------------------------	-------

high-vs-low + GridSearch 튜닝 ~0.90 ← 최종

공시(정직)

- 2-class · 중간 33% 보류(abstain) · 기준선 50% → 90%는 라벨 재정의로만 정직 달성

두 아키텍처를 같은 정답(성공=고매출&장기영업)으로 비교 (GroupKFold)

접근 성공 식별 AUC 특징

① 단일 통합 모델 0.94 (정체성제외 0.90) 예측력 우수, 해석 약함

② 2-모델 융합(0.5:0.5) 0.79 4사분면 해석·진단 가능

검증

- 단일 모델 AUC는 gu/biz 정체성 제외 후에도 0.90 → 실제 입지 신호(암기 아님)

권고 (최종 채택)

- ① 단일 모델 = 성공확률 주 예측기 / ② 융합 = "왜/어느 축이 약한가" 진단으로 병기

permutation importance (테스트 셋, 상위)

- 1 lunch_bias 점심 매출 편중
- 2 age_entropy 연령 매출 분포
- 3 biz_한식음식점 업종 라벨
- 4 TOT_WRC_POPLTN_CO 직장인구
- 5 weekend_bias 주말 편중

그룹 누적 기여

- 카테고리 54.6% / 가공·파생 36.5% / raw 9.1% / 외부변수 -0.18% (≈ 0)

통찰

- 외부변수(임대료·인구밀도) 기여 사실상 0 — 예측은 업종·매출 시간패턴·연령분포·직장인구가 주도

시기별

- 코로나 충격기(20~21) vs 회복기(22~) 결정 변수 다소 변화, 핵심 변수는 공통

업종군별

- 외식·소매·서비스별 결정 변수 차이 — 외식은 시간패턴, 소매는 집객/유동

잔차 분석

- 잔차 절대값 상위 행정동 식별 → 모델 약점 위치를 한계로 명시 (표본 적어 신뢰구간 넓음)

우리 성공확률 vs 창업기상 (순위 상관 r + 값 일치도 Cohen κ)

지표	상관 r	Cohen κ	판정
종합	+0.04	+0.02	무관(다른 차원)
생존	+0.02	-0.04	무관
경쟁력	+0.12	+0.10	약한 일치(수요·매출)

해석

- 우리 모델은 매출·경쟁력 차원 — 공단의 생존 중심 종합지수와 상관도 값도 우연 수준($\kappa \approx 0$)
 - $\rightarrow$ 단순 상관뿐 아니라 같은 척도(백분위)에서 값도 안 맞음 = 경쟁 아닌 보완 관계

우리 생존축(평균 영업기간) vs 창업기상 생존: $r=0.47$, 자치구 일치율 68%

둘 다 좋음 : 서초·종로·중구·동대문·동작·서대문·성북·양천·영등포

둘 다 나쁨 : 강남·마포·송파·성동·강북·강서·관악·광진

엇갈림(8) : 강동·구로·금천·노원·도봉·용산·은평·중랑

엇갈림의 원인 = 측정 시점 차이

- 우리(영업기간) = 기존 점포의 "과거 정착도"(후행) / API = 신규 창업의 "미래 전망"(선행)
- 老·쇠퇴(오래됐지만 폐업 ↑·전망 ↓): 우리 ↑·API ↓ / 신흥·개선(신생이지만 전망 ↑·폐업 ↓): 우리 ↓·API ↑

4사분면 권고

- ① 최적(고매출·고생존) / ② 고위험·고수익(고매출·저생존) / ③ 안정·저성장 / ④ 회피

핵심 사례 — 강남 커피

- 매출 백분위 최상위(100)지만 생존 하위(영업기간·전망 낮음) → ② 고위험·고수익
 - 단일 매출 모델이면 1순위 추천이지만, 통합점수는 “경쟁 포화 함정”을 명시적으로 경고

자치구 종합

- 서초·중구·종로 상위 / 강남은 매출 1위지만 생존이 낮아 종합 중위권

데이터 단위

- 상권 합계/평균만 보유 — 개별 점포 매출·점포 간 분산 없음
 - → 개별 점포 매출·수익·리스크 예측 아님 (상권 단위 스크리닝)
 - → BEP·p_roi(손익분기 초과확률)는 점포 분산 아닌 모델 오차 기반 = 참고용

생존

- 폐업은 노이즈 / 영업기간은 측정 지수 / 진짜 코호트 생존율은 인허가 재수집 필요

정의·범위

- “성공” 정의는 값 선택(7종 민감도로 명시) / 창업기상 매칭 2025 Q3·Q4 × 19업종 한정

처음

- 분류 94% / 회귀 R^2 0.92 달성에 만족 → 보고서 초안까지 작성

발견

- 전수 변수 점검 중 rent_to_sales 등 5개가 매출에서 파생됨을 확인 (타깃 누설)

교정

- 누설 5종 제거 → 84%로 하락. 노트북 nb04~24 전부 재학습, 서술 교정, 감사 문서화(AUDIT_FINDINGS)

추가로 잡은 날조

- nb07 변수순위·nb11 메타데이터(행수 81,604→9,172)·nb13 하이퍼파라미터·nb14 부호(+0.80을 "음의 상관"이라 오기) 등 자기 출력과 모순된 서술 교정
 - 교훈: 높은 정확도는 의심부터. 누설 자기검증이 신뢰도의 출발점

폐업 ML 모델

- 무작위분할 98% → (자치구·업종) 정체성 암기 누설로 판명
- GroupKFold 재측정 → 67%(노이즈). 단일 "성공" 타겟에선 100% 누설도 적발

폐업률 자체 진단

- 자치구·업종·분기 split-half 0.28 → 노이즈 / 자치구·연 $r=0.97$ → 안정 (단위 문제)

전환

- 폐업 예측 폐기 → 측정 지수(평균 영업기간, 신뢰도 0.94)로 생존측 재설계
 - 교훈: 같은 누설 함정이 반복됨 → 검증 설계(GroupKFold)가 본질

API 재현(distillation) 시도 → 폐기

- 우리 피쳐로 창업기상 생존을 $R^2 0.4 \sim AUC 0.74$ 로 근사 가능했으나, "외부 지수 모방"이라 자체성 약해 폐기

90% 집착 → 정직 경로로

- 데이터·변수 추가로는 90% 불가(실측) → 라벨 재정의(high-vs-low)로 정직 달성

평가 지표 재정의

- "생존을 정확도로 평가"가 잘못 → 측정 지수의 신뢰도·타당도 관점으로 교정

빌드 사고 복구

- stale 생성기가 노트북을 되돌리는 사고 → build 스크립트 자기완결화로 복구
 - 교훈: 목표(90%) 집착이 누설을 부른다. 정직한 재정의가 답

상관만 보다가 → 값 일치도까지

- API 비교에서 상관(r)만 보면 놓침 → Cohen κ ·이진 일치율·CCC로 “값도 맞나” 확인

단일 분할 → GroupKFold

- 정체성 누수를 못 잡던 무작위 분할 → 그룹 분할로 거짓 성능 제거

단일 정의 → 정의 민감도

- “성공” 하나로 단정하지 않고 7종 비교로 정의 의존성 노출

한계의 명시 = 기여

- 측정 불가(개별 점포·진짜 생존)는 숨기지 않고 한계·후속과제로 전환

산출물

- (자치구·업종) 통합 입지점수 + 4사분면 등급 + 성공확률(단일 통합 모델 AUC 0.94)

정직 성능

- 매출 이진 84% / 명확등급 90% / 회귀 R^2 0.64 — 누설 0, GroupKFold·홀드아웃·외부 API 교차검증

차별점

- (1) 타깃 누설 자기발견·제거 (2) 생존축(영업기간) 설계 (3) 창업기상도 비교(과거 vs 미래) (4) 정직한 한계 명시

핵심 통찰

- 강남형 “고매출·저생존” 함정을 통합점수가 경고 — 매출만으론 못 잡는 입지 위험을 2축으로 포착

개별 점포 단위로

- 소상공인 상가정보 / 카드매출 마이크로데이터 → 점포 분산·개별 예측·진짜 BEP 확률

진짜 생존율

- 행안부 지방행정인허가(개·폐업일) 코호트 → Kaplan-Meier 생존곡선·1/3/5년 생존율

창업기상도 확대

- 업종·기간 확대 수집 → 생존축 외부 검증 강화

마무리

- 정직성(누설 검증·한계 명시)을 갖춘 "상권 단위 1차 입지 스크리닝 도구" — 실제 창업은 점포 실사 병행